

MEMORIA ESCRITA DEL PROYECTO

Curso de especialización en Inteligencia Artificial y Big Data

House Data

Autor: Alex Martín

Tutor: Borja Lanza

Fecha de entrega: 18/05/2026

Convocatoria: 2s2526

Documentos del proyecto:



Índice

Índice	1
Índice Imágenes	4
Índice Tablas	5
1. Introducción	6
1.1 Motivación	6
1.2. Abstract (Keywords)	7
1.3 Objetivos propuestos (generales y específicos)	8
2. Estado del Arte	9
2.1. Evolución del Análisis y PropTech	9
2.2. Fuentes de Datos y Open Data	9
2.3. Aplicación de la IA y Economía	10
2.4. Herramientas de Visualización y Despliegue	11
2.5. Datos Reales (Justificación del proyecto)	12
3. Metodología usada	13
3.1. Gestión del Ciclo de Vida del Dato (Arquitectura Medallion)	13
3.2. Análisis Exploratorio de Datos (EDA)	14
3.3. Desarrollo del Modelo de Inteligencia Artificial	14
3.4. Implementación de la Solución de Visualización	15
4. Tecnologías y herramientas utilizadas en el proyecto	16
4.1. Entorno de Gestión y Distribución: Anaconda	16
4.2. Lenguaje de Programación: Python	16
4.3. Procesamiento y Manipulación de Datos: Pandas y NumPy	16
4.4. Stack de Visualización Dinámica e Interactiva	17
4.5. Inteligencia Artificial: Scikit-Learn	17
4.6. Almacenamiento, Control de Versiones y Despliegue: GitHub	17
4.7. Aplicación Web y Presentación de Resultados	18
5. Planificación, Diagnóstico y Contexto Laboral	19
5.1. Metodología de Gestión y Cronograma (Gantt)	19

5.2. Diagnóstico Estratégico (DAFO)	20
5.3. Contexto Laboral y Ética del Dato	21
6. Análisis del proyecto	22
6.1. Análisis de requisitos	22
6.1.1. Requisitos Funcionales (RF)	22
6.1.2. Requisitos No Funcionales (RNF)	23
6.2. Descripción de las fuentes de datos	23
6.2.1. Índice de Precios de Vivienda (IPV)	23
6.2.2. Índice de Precios de Consumo (IPC)	24
6.2.3. Renta Media por Comunidad Autónoma	25
6.2.4. Estadística del Padrón (Población por Edad)	25
6.2.5. Procesamiento y Calidad de Datos (Capa Silver)	26
6.2.6. Consolidación de la Tabla Maestra (Capa Gold)	29
6.4. Análisis Exploratorio Visual (EDA)	30
6.4.1. Contexto Internacional: España vs. Unión Europea	31
6.4.2. Disparidad Regional y Poder Adquisitivo	32
6.4.3. El Indicador Crítico: Ratio de Esfuerzo y Demografía	33
6.4.4. Distribución de Datos y Densidad (Violin Plot)	34
6.5 Diagnóstico Estadístico (Matriz de Correlación)	35
6.6 Conclusiones del Análisis y Clasificación de Riesgo	36
6.6.1. Ranking de Emergencia por CCAA	36
6.6.2. Casos de Uso del Proyecto	36
7. Diseño del proyecto	37
7.1. Diseño de la Arquitectura de Datos (Medallion Architecture)	37
7.1.1. Capa Bronze (Raw Data)	38
7.1.2. Capa Silver (Cleaned Data)	38
7.1.3. Capa Gold (Business Logic)	38
7.2. Diseño del Almacenamiento y Estructura de Datos	39
7.2.1. Modelo de Datos Desnormalizado	39
7.2.2. Diccionario de Datos (Diseño de la Capa Gold)	40

7.2.3. Estrategia de Interoperabilidad	40
7.3 Algoritmo	40
7.3.1. Selección del Algoritmo: Hist Gradient Boosting Regressor	40
7.3.2. Arquitectura de Entrenamiento (Pipeline)	41
7.3.3. Conclusiones del Modelo Predictivo y Validación Estadística	41
7.4. Diseño de la Interfaz de Usuario y Visualización	43
7.4.1. Dashboard de Inteligencia de Negocio (Power BI)	43
7.4.2. Aplicación de Simulación y Predicción (Streamlit)	44
7.5. Diseño del Flujo de Ejecución y Control de Errores	45
7.5.1. Ciclo de Vida de la Inferencia	45
7.5.2. Diseño de la Persistencia y Disponibilidad	46
8. Despliegue y pruebas	47
8.1. Tabla Resumen de Pruebas Ejecutadas	47
8.2. Validación de Integridad Estructural (Capa Gold)	47
8.3. Pruebas de Interfaz de Usuario e Inferencia (Streamlit)	48
8.4. Verificación Visual y de Lógica de Interfaz	49
8.5. Validación Estratégica: Cotejo 2023 y Escenarios de Control	50
8.5.1 Cotejo con Datos Reales (Backtesting 2023)	50
8.5.2. Test de Estrés y Sensibilidad: El caso de Extremadura	52
8.5.3. Identificación de sesgos en mercados de alta tensión (Caso Baleares)	53
8.6 Dashboard Histórico	54
8.6.1. Indicadores Clave de Rendimiento (KPIs)	54
8.6.2. Desglose Visual y Distribución Geográfica	55
8.6.3 Conclusión del Análisis y Sinergia del Ecosistema	55
9. Conclusiones	56
10. Vías futuras	58
10.1. Incremento de la Granularidad y Análisis Geoespacial	58
10.2. Enriquecimiento Multifuente y Big Data	58
10.3. Evolución del Modelo de IA y ML Predictivo	59
10.4. Arquitectura MLOps y Despliegue en la Nube	59

11. Bibliografía/Webgrafía	60
12. Anexos	62
12.1 Manual de Instalación	62
12.2 Manual de Usuario (Guía de Explotación y Análisis)	63
12.3 Tablas	64
12.4 Imágenes	69

Índice Imágenes

Figura 1. Diagrama Gantt Distribución tiempos Proyecto	19
Figura 2. Diagnóstico Estratégico (DAFO)	20
Figura 3. Dataset IPV (Vivienda)	24
Figura 4. Dataset IPC	24
Figura 5. Dataset Renta CCAA	25
Figura 6. Dataset Población	26
Figura 7. Datos Brutos	27
Figura 9. Consolidación anual	27
Figura 10. Eliminación valores nulos y redundantes	28
Figura 12. Variables Creadas	29
Figura 13. Dataset Final	30
Figura 14. Gráfico Lineas España/UE	31
Figura 16. Evolución Renta por CCAA	32
Figura 21. Matriz de Correlación	35
Figura 23. Código Merge Dataset Final	39
Figura 24. Modelo Hist Gradient Boosting Regressor	40
Figura 25. Conclusiones Modelo IA	43
Figura 26. Comprobación Valores Nulos	48
Figura 28. Aviso Simulador	50
Figura 33. Dashboard Histórico	54
Figura 15. Gráfico Barras Brecha España/UE	69
Figura 17. Mapa Renta por CCAA	69
Figura 19. Scatter Plot Esfuerzo CCAA y Población Juvenil	70
Figura 22. Diseño Arquitectura Datos	71
Figura 30. Simulación de mercado Extremadura.	72
Figura 31. Detección de cambio tendencia IPV.	73
Figura 32. Tendencia Contraria	74

Índice Tablas

Tabla 5. Cotejo Datos 2023	51
Tabla 1: Clasificación Riesgo CCAA	64
Tabla 2: Diccionario Datos Dataset Final	66
Tabla 3: Clasificación Utilidad del Cuadro de Mandos	67
Tabla 4. Resumen Pruebas Ejecutadas	68

1. Introducción

(3-4 Páginas)

1.1 Motivación

El proyecto **House Data** surge de la necesidad de confrontar una realidad socioeconómica que afecta de manera directa a la generación joven en España. Motivado por una trayectoria vital que ha permitido adquirir una conciencia temprana sobre el funcionamiento del mercado, se observa con preocupación la creciente dificultad de acceso a la vivienda. Este trabajo no solo nace de una inquietud personal, sino de la voluntad de ofrecer claridad ante un escenario inmobiliario complejo. El propósito es concienciar y dotar de herramientas a los jóvenes que se enfrentan a un mercado al alza donde la proactividad y el análisis de datos son esenciales para comprender —y tratar de mitigar— la vulnerabilidad del futuro residencial.

El presente proyecto se lanza por todos aquellos jóvenes que quizás no perciben con claridad la situación actual. El objetivo es concienciar a la sociedad sobre la tendencia alcista de los inmuebles, concretamente en España. La realidad es que, si no existe una proactividad por entender el problema, difícilmente se obtendrán soluciones externas.

Además, existe un fuerte componente de interés analítico. Dada la relevancia de la economía, resulta fundamental seguir de cerca las noticias globales para proteger el futuro financiero. Por ello, al realizar este proyecto, lo que se busca es recopilar información real que narre la historia de la evolución de España en estos últimos años, comparándola con otros países para determinar si la calidad de vida evoluciona de manera equilibrada.

Actualmente, el sector inmobiliario y los alquileres desproporcionados en ciudades específicas son temas de debate constante. El propósito de este estudio es trascender la información superficial, llegando al fondo del asunto mediante datos objetivos para obtener conclusiones propias. Para ello se utiliza la ciencia de datos: para verificar si la relación entre sueldos y precios de vivienda es coherente o si se trata de un problema estructural más profundo. En última instancia, este proyecto es una forma de preparación ante los retos venideros y una vía para ayudar a otros a comprender la realidad del mercado.

House Data no pretende ser únicamente un análisis retrospectivo, sino una herramienta con visión de futuro. Motiva el reto de emplear la Inteligencia Artificial para intentar predecir si la tendencia seguirá afectando a la generación actual o si existen indicadores que ofrezcan una guía. Se trata de procesar toda la información de manera conjunta para realizar un análisis técnico que permita anticiparse a los movimientos del mercado, en lugar de reaccionar a ellos de forma tardía.

Este trabajo es, en esencia, una respuesta a un sistema que en ocasiones parece ignorar que el acceso a un hogar es la base para que cualquier joven pueda desarrollar su vida con libertad y seguridad, siendo uno de los pilares primordiales para el crecimiento del país.

Por último, este proyecto representa un reto para demostrar la aplicación de los conocimientos adquiridos en una problemática de impacto real para la sociedad. No se ha seleccionado un tema al azar, sino uno que afecta directamente al entorno generacional del autor. Existe la oportunidad de crear una herramienta que ayude a que otros jóvenes dejen de percibir la economía como algo ajeno, y comiencen a verla como la base de la libertad y del futuro acceso a la vivienda.

1.2. Abstract (Keywords)

Castellano:

El proyecto **House Data** presenta un análisis detallado sobre la crisis de acceso a la vivienda en España durante el periodo 2008-2022. El estudio surge de la necesidad de comprender, mediante el análisis de datos objetivos, los factores que condicionan el mercado inmobiliario actual para la población joven. Utilizando Python y fuentes oficiales del INE, se integran indicadores de precios, salarios e inflación para contextualizar la situación española frente a la media europea.

La metodología implementada combina un análisis histórico exhaustivo, apoyado en visualizaciones de Power BI, con el desarrollo de un modelo de Inteligencia Artificial (regresión supervisada) destinado a predecir tendencias futuras. Finalmente, el ecosistema se despliega en una aplicación interactiva mediante Streamlit. El objetivo final es transformar datos complejos en conclusiones estratégicas que fomenten la concienciación sobre la realidad del sector inmobiliario y su impacto socioeconómico.

Palabras clave: Sector inmobiliario, España, Vivienda, Análisis de datos, Python, Power BI, Predicción, INE, Machine Learning.

English:

The HouseData project presents a detailed analysis of the housing access crisis in Spain between 2008 and 2022. The study arises from the need to understand, through objective data analysis, the factors shaping the current real estate market for the younger population. Using Python and official sources from the INE, indicators of prices, wages, and inflation are integrated to contextualize the Spanish situation against the European average.

The implemented methodology combines an exhaustive historical analysis, supported by Power BI visualizations, with the development of an Artificial Intelligence model (supervised regression) aimed at predicting future trends. Finally, the ecosystem is deployed in an interactive application using Streamlit. The ultimate goal is to transform complex data into strategic insights that raise awareness about the reality of the real estate sector and its socio-economic impact.

Keywords: Real Estate, Spain, Housing, Data Analysis, Python, Power BI, Prediction, INE, Machine Learning.

1.3 Objetivos propuestos (generales y específicos)

Objetivo General

Analizar el impacto de la coyuntura económica en el acceso a la vivienda en España (2008-2022) mediante un estudio comparativo a nivel europeo, con el fin de desarrollar una herramienta tecnológica de análisis de datos que permita proyectar escenarios futuros y fomentar la concienciación financiera entre los jóvenes.

Objetivos Específicos

1. **Contextualización Internacional:** Evaluar la posición del mercado inmobiliario español en comparación con la media de la Unión Europea.
2. **Integración de Datos (Fusión):** Implementar una arquitectura de datos que unifique fuentes heterogéneas del INE (precios, salarios, inflación y demografía).
3. **Análisis Exploratorio e Histórico (Business Intelligence):** Desarrollar un cuadro de mandos interactivo en **Power BI** para explorar las tendencias históricas
4. **Modelado Predictivo:** Desarrollar un algoritmo de regresión capaz de proyectar tendencias futuras basadas en el histórico analizado.

2. Estado del Arte

(4-5 páginas)

2.1. Evolución del Análisis y PropTech

El sector inmobiliario en España ha dejado de ser un mercado puramente físico para convertirse en un ecosistema tecnológico avanzado. En los últimos años, se ha observado una tendencia alcista clara en la que se están incorporando cientos de empresas que impulsan la innovación a través del concepto **PropTech**. Según el último informe de **PwC España** (2025), el sector ha alcanzado un récord histórico con 870 empresas innovadoras activas, lo que demuestra que la tecnología ya no es una opción, sino el motor principal del mercado.

Anteriormente, el análisis del mercado dependía casi exclusivamente de informes del Ministerio o del INE, los cuales se publicaban con desfases temporales de varios meses. Esta demora provocaba que la información perdiera calidad antes de ser procesada. En la actualidad, gracias a herramientas como **DataVenues** (2024), es posible analizar millones de datos diariamente en tiempo real. Este cambio resulta fundamental para profesionales e inversores, ya que permite sustituir las decisiones basadas en intuiciones o tendencias pasajeras por el uso de datos reales obtenidos en tiempo récord.

A su vez, portales líderes como **Idealista** (2025) o **Fotocasa** (2025) han evolucionado significativamente; han dejado de ser únicamente marketplaces de anuncios para transformarse en plataformas que gestionan datos en tiempo real y ofrecen valoraciones automáticas mediante modelos **AVM** (Automated Valuation Models). Esta transformación permite que cualquier usuario o profesional consulte el estado del mercado al instante, obteniendo información de oferta y demanda con una precisión históricamente difícil de alcanzar. El proyecto **House Data** se sitúa precisamente en esta evolución tecnológica: se utiliza la potencia de los datos masivos para comprender una problemática que, tradicionalmente, se analizaba mediante estadísticas estáticas.

2.2. Fuentes de Datos y Open Data

Los datos abiertos o Open Data son activos informáticos a los que cualquier persona puede acceder, utilizar y compartir de forma libre. Tanto los Gobiernos como las empresas y la ciudadanía pueden emplear estos recursos para generar beneficios

sociales, económicos o medioambientales, entre otros. En el contexto de este proyecto, estos datos constituyen la base para realizar un análisis objetivo y real del mercado inmobiliario.

Según el informe **Open Data Maturity 2025** de la Unión Europea, España se mantiene en el grupo de los **Trend-setters** o marcadores de tendencias. Con una puntuación del **95,6%**, el país destaca especialmente por la calidad de sus portales y por la facilidad proporcionada a los analistas para la reutilización de la información pública. Esta infraestructura es la que permite que proyectos de análisis de datos tengan acceso a fuentes de alta calidad.

Un pilar fundamental en la arquitectura de datos de este trabajo es el servicio del **Instituto Nacional de Estadística** (INE). Este sistema permite que la información almacenada en series temporales sea accesible mediante datasets en formato CSV. Dicha característica es clave, ya que facilita el manejo de grandes volúmenes de información y permite que entornos de programación como **Python** procesen los datos directamente, minimizando errores humanos y permitiendo un análisis exhaustivo de la serie histórica.

Finalmente, resulta imprescindible mencionar la labor de **Eurostat** (2025). Este organismo es el encargado de dictar las reglas estadísticas en la Unión Europea, lo que garantiza que los datos utilizados para comparar a España con otros países vecinos sean fiables y se rijan bajo los mismos estándares de medición internacional.

2.3. Aplicación de la IA y Economía

El estudio reciente del **Banco de España** (BE, 2024) comenta que, desde 2014, existe una creciente subida de precios en el sector inmobiliario debido a la poca oferta de obra nueva y al incremento demográfico. Esta evidencia muestra un impacto notable en el mercado, donde factores como el crecimiento de la población y la demanda de no residentes han resultado determinantes en la evolución de los precios.

Para entender este desorden de precios, actualmente se utilizan tecnologías de **Machine Learning**. Los algoritmos más comunes, considerados el estándar en el sector, son la Regresión Lineal y el Random Forest. Mientras que la Regresión Lineal facilita la comprensión de la relación directa entre el nivel de ingresos y el coste, el modelo

Random Forest permite identificar patrones más complejos y relaciones que pasan desapercibidas.

En este proyecto, la Inteligencia Artificial, no se aplica para analizar las características individuales de los inmuebles (como materiales o dimensiones), sino para realizar un análisis macroeconómico: el nivel de ingresos, la inflación y las variaciones demográficas. El uso de estas herramientas resulta clave para identificar riesgos reales respecto a la vivienda. En última instancia, la combinación de series históricas con estos modelos de predicción es lo que permite establecer una base objetiva para la toma de decisiones, evitando el sesgo de las opiniones subjetivas.

2.4. Herramientas de Visualización y Despliegue

En la actualidad, la inmensa cantidad de información disponible ha provocado que los informes tradicionales pierdan fuerza. Empresas líderes en el sector del Big Data como **Databricks** (2025) defienden que el futuro reside en el **Data Storytelling**. Esta técnica no consiste simplemente en crear gráficos, sino en combinar los datos con una narrativa visual que ayude a explicar el contexto y el significado de los números.

Siguiendo esta tendencia, el proyecto **House Data** se desarrolla bajo la premisa de “avivar” la información. Al transformar los complejos datasets del **INE** en una historia visual interactiva, se evita la saturación del usuario en un entorno denso de datos, dando paso a la exploración de forma autónoma cómo los factores económicos han afectado a la capacidad de acceso a la vivienda.

Por otro lado, para la visualización completa de la parte histórica, se emplea el estándar de visualización en la industria: **Power BI**. Se considera la herramienta más adecuada al permitir la aplicación de análisis de forma visual e intuitiva para el espectador. Mediante la creación de **dashboards dinámicos**, el usuario puede filtrar los datos por año o provincia, facilitando la comprensión y la inmersión en la evolución del mercado inmobiliario sin necesidad de poseer conocimientos expertos en la materia.

Para acabar, el modelo de regresión y la fase de predicción se despliegan en una interfaz web funcional mediante **Streamlit**. Esta plataforma es muy reconocida en el ámbito del **Big Data** y la **Ciencia de Datos** ya que permite convertir scripts de **Python** en aplicaciones interactivas de forma rápida y eficiente. De esta forma, el modelo de

Inteligencia Artificial trasciende el código fuente para convertirse en una herramienta práctica que permite consultar predicciones futuras de forma ágil.

2.5. Datos Reales (Justificación del proyecto)

Tras analizar la situación actual, se observa una realidad crítica reflejada en los datos del **Consejo de la Juventud de España** (CJE, 2025). Actualmente, la tasa de emancipación en España ha caído al **14,8%**, situándose en el mínimo histórico registrado desde 2006. Esta situación se explica por una brecha insostenible: mientras que los salarios jóvenes han experimentado un incremento del **10,8%** desde 2008, el precio de los alquileres se ha disparado en un **54%** en el mismo periodo.

A pesar de los portales inmobiliarios y noticias sobre el sector, la mayoría de las herramientas digitales actuales se centran en la oferta comercial y omiten el análisis del impacto social. Si bien la juventud tiene acceso a información sobre la problemática a través de diversas plataformas, a menudo carece de una visión integral que permita comprender su capacidad adquisitiva real frente al mercado.

House Data yace con el propósito de cubrir este vacío informativo. A diferencia de las plataformas orientadas exclusivamente a la venta, este proyecto utiliza la **Ciencia de Datos** y la **IA** para pronunciar y demostrar, mediante datos oficiales, cómo el coste de la vivienda —que ya supera la mediana de los **1.072 euros**— obliga a que el alquiler individual requiera destinar más del **100%** del salario neto anual de un joven medio. Este trabajo no se limita al análisis retrospectivo, sino que ofrece una herramienta predictiva para comprender la evolución de un mercado de alta complejidad, el cual constituye uno de los pilares fundamentales para el desarrollo socioeconómico del país.

3. Metodología usada

(2-4 páginas)

Para el desarrollo de **House Data**, se ha seguido un flujo de trabajo que permite la transformación de datos en bruto (datasets CSV) en visualizaciones estratégicas y modelos predictivos. El objetivo principal es garantizar que la información cruda extraída del INE se transforme en conocimiento útil y fiable para el modelo de Inteligencia Artificial.

3.1. Gestión del Ciclo de Vida del Dato (Arquitectura Medallion)

El procesamiento de la información se ha organizado siguiendo la arquitectura **Medallion**, la cual divide el trabajo en tres capas de calidad creciente:

Capa Bronze (Ingesta): En esta fase inicial, se han integrado los cinco archivos fuente en su formato original (.csv). El reto técnico en esta capa ha sido la gestión de codificaciones, ya que los archivos del **INE** utilizan el estándar **ISO-8859-1 (Latin-1)**. Los datos se cargan en el entorno de **Python** mediante la librería **Pandas**, manteniendo la fidelidad absoluta a la fuente.

Fuentes integradas: IPC mensual (2002-2025), IPV trimestral (2007-2024), Población anual, Renta Media por CCAA y el histórico de Renta España-UE.

Capa Silver (Limpieza y Normalización): Esta fase representa la mayor carga técnica, donde se resuelven las discrepancias entre formatos:

Normalización de Tipos: Se ha realizado una conversión de tipos de datos (casting). Debido al formato de origen utiliza el punto para los miles y la coma para los decimales, se han implementado funciones de limpieza de cadenas para transformar estos valores en tipos (float) para poder utilizarlos sin errores.

Sincronización Temporal: Al disponer de datos con distintas periodicidades (mensuales y trimestrales), se ha aplicado una operación de agregación temporal, calculando las medias aritméticas anuales para homogeneizar todas las variables del proyecto.

Homogeneización de Identificadores: Mediante el uso de expresiones regulares (Regex), se han depurado los prefijos numéricos de las Comunidades Autónomas, garantizando que las operaciones de cruce de tablas (joins) sean precisas.

Capa Gold (Integración y Enriquecimiento): En la capa final, se ha consolidado una **Tabla Maestra (Master Dataset)**. Cada registro representa una combinación única de Año y CCAA.

Feature Engineering: Se han creado variables derivadas para potenciar la capacidad del modelo, destacando el **Ratio de Esfuerzo**, que vincula la renta disponible con el Índice de Precios de Vivienda (IPV).

Contextualización Internacional: Se ha integrado el dataset `Renta_España-UE.csv` para mostrar un marco de referencia (benchmark) que permita comparar España respecto a la media de la Unión Europea.

3.2. Análisis Exploratorio de Datos (EDA)

Previamente al entrenamiento del modelo, se realiza un EDA exhaustivo para validar las hipótesis de investigación. En esta fase se emplean histogramas y diagramas de dispersión para abordar los siguientes niveles de análisis:

Nivel Macro (Internacional): Comparativa del crecimiento de renta en España frente a la UE.

Nivel Medio (Nacional): Análisis de correlación mediante mapas de calor (heatmaps) para determinar el grado de dependencia entre (IPC) y el coste de la vivienda.

Nivel Micro (Regional): Identificación de valores atípicos (outliers) en regiones con mercados tensionados, como Madrid, Cataluña o Baleares.

Este análisis es clave para el uso posterior de la Regresión Lineal, ya que permite confirmar si la distribución de los datos sigue una tendencia adecuada.

3.3. Desarrollo del Modelo de Inteligencia Artificial

Para la fase predictiva, se ha optado por un enfoque de **Aprendizaje Supervisado**:

Algoritmo Principal: Se ha seleccionado el **HistGradientBoostingRegressor**, una implementación avanzada de *Gradient Boosting* inspirada en LightGBM. Este algoritmo destaca por su capacidad para modelar relaciones **no lineales** complejas y capturar interacciones entre variables económicas que los modelos tradicionales ignoran. Al basarse en un **ensamblado de árboles de decisión**, el modelo es especialmente

robusto frente a valores atípicos (*outliers*) y gestiona de forma eficiente las series temporales históricas mediante la técnica de "binning" (agrupación en contenedores), lo que optimiza el entrenamiento y mejora la precisión en la proyección de tendencias de mercado.

Métricas de Evaluación: La precisión se cuantifica mediante el coeficiente de determinación (R^2) y el Error Absoluto Medio (**MAE**), este último para valorar la desviación en términos monetarios reales.

Estrategia de Validación (Backtesting): Se ha definido el periodo 2008-2022 para el entrenamiento, reservando el año 2023 como "test ciego". La comparación entre la predicción y el dato real de 2023 proporciona el porcentaje de error real de la herramienta.

3.4. Implementación de la Solución de Visualización

La metodología concluye con la transferencia de valor al usuario a través de dos entornos diferenciados:

1. **Análisis Histórico (Power BI):** Un cuadro de mando interactivo centrado en el análisis descriptivo, que permite navegar desde lo global hasta el detalle provincial.
2. **Herramienta Predictiva (Streamlit):** Una aplicación web interactiva que ejecuta el modelo de IA en tiempo real, permitiendo obtener estimaciones basadas en diferentes escenarios macroeconómicos.

4. Tecnologías y herramientas utilizadas en el proyecto

(2-3 páginas)

El desarrollo del proyecto **House Data** se reparte en un stack tecnológico moderno, priorizando herramientas de código abierto (open-source) que permiten la escalabilidad, la realización del análisis y un despliegue ágil en la nube. La elección de estas herramientas ha sido pensando a futuro (entorno laboral) y respondiendo a las necesidades técnicas de cada fase del ciclo de vida del dato.

4.1. Entorno de Gestión y Distribución: Anaconda

Como base del ecosistema de trabajo se ha utilizado **Anaconda**:

Gestión de Entornos (Conda): Se ha configurado un entorno virtual específico para garantizar que las librerías (Pandas, Scikit-Learn, Plotly) mantengan versiones estables, evitando conflictos de dependencias que podrían afectar la ejecución del código en otras máquinas.

- **Jupyter Notebook:** Se ha empleado como el IDE (*Integrated Development Environment*) principal. Esta herramienta ha permitido unificar en un solo flujo de trabajo el código ejecutable y las visualizaciones dinámicas.

4.2. Lenguaje de Programación: Python

Se ha seleccionado **Python** (versión 3.x) como lenguaje debido a su ecosistema y popularidad en Inteligencia Artificial. Su versatilidad ha permitido desde la ingesta de datos crudos hasta el entrenamiento de modelos de aprendizaje supervisado, manteniendo una sintaxis clara que facilita la mantenibilidad y si es el caso, evolución futura del proyecto.

4.3. Procesamiento y Manipulación de Datos: Pandas y NumPy

Para ejecutar la **arquitectura Medallion** (Capas Bronze, Silver y Gold), se han utilizado las siguientes librerías de manipulación de datos:

- **Pandas:** Herramienta fundamental para el análisis de estructuras de datos. Se ha utilizado para la limpieza de valores nulos, la normalización de nombres de las

Comunidades Autónomas y la fusión compleja (*merge*) de los cuatro datasets originales del INE mediante valores claves.

- **NumPy:** Utilizada para operaciones y el manejo de matrices numéricas, además de la creación de nuevas métricas analíticas como el "Ratio de Esfuerzo".

4.4. Stack de Visualización Dinámica e Interactiva

Se han implementado:

- **Análisis Exploratorio y Correlación (Matplotlib & Seaborn):** Se han usado para la etapa de EDA (Exploratory Data Analysis), permitiendo identificar mediante matrices de calor la influencia de variables macroeconómicas (IPC, demografía) en el mercado inmobiliario.
- **Visualización (Plotly):** Se ha utilizado para transformar datos estáticos en herramientas de consulta dinámica. Como los mapas coropléticos vinculados a **GeoJSON** para análisis territorial y gráficos animados (*Bar Chart Race*) para representar la evolución temporal de la riqueza.

4.5. Inteligencia Artificial: Scikit-Learn

Para la fase de modelado predictivo, se ha optado por **Scikit-Learn**:

- **Modelado Hist Gradient Boosting Regressor:** Se han entrenado algoritmos de aprendizaje supervisado para proyectar las tendencias del mercado inmobiliario.
- **Validación:** Se utilizan métricas de error (MAE, R2) para asegurar que las predicciones del modelo sobre el escenario de 2023 y futuros años tengan respaldo científico y estadístico.

4.6. Almacenamiento, Control de Versiones y Despliegue: GitHub

El proyecto se centraliza en un repositorio de **GitHub**, que actúa como el núcleo de la infraestructura del software:

- **Control de versiones:** Permite mantener un historial detallado de cambios y asegura el código frente a posibles errores durante la fase de desarrollo.
- **README y Documentación:** El repositorio cuenta con un archivo README técnico que detalla la estructura del proyecto, las dependencias y las instrucciones de ejecución, facilitando la transparencia y la ejecución por parte de terceros.

- **Base para el Despliegue:** GitHub sirve como fuente de datos para el servidor de despliegue, permitiendo una sincronización en tiempo real entre el código desarrollado y la plataforma web.

4.7. Aplicación Web y Presentación de Resultados

Para la entrega final y la interacción con el usuario, se han integrado:

- **Streamlit:** Framework que permite transformar los scripts de Python en una **aplicación web interactiva**. En esta plataforma se despliega el modelo de IA, permitiendo al usuario final introducir variables y obtener predicciones al instante.
- **Power BI:** Se utiliza como herramienta complementaria para el análisis descriptivo histórico, ofreciendo una perspectiva de inteligencia de negocio donde visualizamos los datos encontrados en el análisis de Python.
- **Herramientas de Diseño y Multimedia (Canva y OBS Studio):** Utilizadas para la creación de la presentación y la grabación de la demostración práctica.

5. Planificación, Diagnóstico y Contexto Laboral

(3-4 páginas)

5.1. Metodología de Gestión y Cronograma (Gantt)

Para la ejecución de **HouseData**, se ha seguido una metodología de gestión por fases, asegurando que cada etapa técnica tuviera una base sólida antes de avanzar a la siguiente. La planificación se ha estructurado desde la concepción del proyecto en febrero hasta su entrega final en mayo, dividiéndose en tres grandes bloques: Definición, Ingeniería/IA y Visualización.




Figura 1. Diagrama Gantt Distribución tiempos Proyecto

Fuente: Elaboración propia

Como se observa en el cronograma, se ha otorgado una importancia capital a la fase de **Ingeniería de Datos (Arquitectura Medallion)** durante los meses de marzo y abril. Esta decisión técnica responde a que la precisión de las predicciones de la IA depende directamente de la calidad y limpieza de los *datasets* utilizados. De forma paralela, la redacción de la memoria se ha definido como una tarea transversal, permitiendo la documentación técnica de cada hallazgo en tiempo real.

5.2. Diagnóstico Estratégico (DAFO)

Para evaluar la viabilidad del proyecto y anticipar posibles errores, se ha realizado un análisis DAFO (Debilidades, Amenazas, Fortalezas y Oportunidades). Este ejercicio permite entender la posición estratégica de **HouseData** con una visión total.



Figura 2. Diagnóstico Estratégico (DAFO)

Fuente: Elaboración propia

El análisis destaca como principal fortaleza el uso exclusivo de fuentes 100% oficiales, lo que otorga al proyecto una transparencia y fiabilidad superior. Por otro lado, se identifica la volatilidad económica como una amenaza externa, la cual se ha mitigado mediante el empleo de modelos de regresión robustos y la validación con datos reales consolidados del ejercicio 2023.

5.3. Contexto Laboral y Ética del Dato

Este proyecto no solo posee un marco técnico, sino que se integra en un contexto laboral y social de gran relevancia. Según el **Consejo de la Juventud de España** (2025), la precariedad laboral y la dificultad de acceso a la vivienda representan los principales obstáculos para el desarrollo de la población joven en España. Esta problemática afecta de manera transversal a todos los residentes, aunque el segmento joven percibe de forma más acentuada estos cambios estructurales.

Desde la perspectiva del analista de datos, **House Data** cumple una función ética esencial: centralizar y democratizar el acceso a información de alta complejidad. En un entorno profesional donde el tratamiento de datos suele priorizar fines lucrativos, este trabajo demuestra que la **Ciencia de Datos** puede actuar como una herramienta de concienciación social, facilitando la toma de decisiones informada para ciudadanos particulares y no solo para grandes instituciones financieras.

La magnitud de este desequilibrio es evidente al analizar el contraste histórico en mercados tensionados como el de Barcelona. Mientras que en décadas anteriores un perfil trabajador promedio podía adquirir una vivienda con un periodo de ahorro íntegro relativamente corto, en la actualidad dicha meta resulta matemáticamente inalcanzable para un perfil con salario medio.

Esta disparidad evidencia que el valor del trabajo no ha evolucionado al mismo ritmo que el precio de los activos inmuebles. Existe una desconexión estructural entre el poder adquisitivo y el coste de vida; una realidad que **House Data** se propone evidenciar y exponer mediante el análisis de datos reales en el ámbito residencial.

6. Análisis del proyecto

(8-16 páginas)

6.1. Análisis de requisitos

El presente proyecto nace de la necesidad de proporcionar una plataforma analítica integral (descriptiva y predictiva) que permita diagnosticar la crisis de accesibilidad a la vivienda en España, con especial foco en el sector demográfico joven. Para garantizar el éxito de la solución técnica y la correcta explotación de los datos, se han definido los siguientes requisitos detallados:

6.1.1. Requisitos Funcionales (RF)

Los requisitos funcionales definen las capacidades que el sistema debe ofrecer al usuario final para satisfacer las necesidades de análisis:

- **RF-01: Ingesta y Arquitectura Multifuente:** El sistema debe procesar, normalizar e integrar datos heterogéneos de fuentes oficiales (INE), gobernando el ciclo de vida del dato mediante una arquitectura Medallion (Bronze, Silver y Gold) que asegure la trazabilidad.
- **RF-02: Modelado Analítico de Métricas Relativas:** El sistema debe consolidar las variables en la capa Gold para calcular indicadores clave de esfuerzo, cruzando el Índice de Precios de Vivienda (IPV) con la Renta Media disponible por Comunidad Autónoma.
- **RF-03: Inteligencia de Negocio e Histórico (Power BI):** El sistema debe alimentar un cuadro de mando interactivo en Power BI que permita realizar un análisis descriptivo del histórico (2008-2022), identificar patrones del pasado y brechas respecto a la Unión Europea.
- **RF-04: Análisis Geoespacial y Drill-Down Regional:** Las herramientas de visualización deben permitir el filtrado dinámico mediante mapas coropléticos para diagnosticar territorialmente las zonas de exclusión y tensión inmobiliaria a nivel de Comunidad Autónoma.
- **RF-06: Simulación Predictiva de Escenarios (IA):** Implementación de un modelo predictivo basado en aprendizaje automático capaz de proyectar

tendencias del IPV en función de variaciones simuladas en variables macroeconómicas como el IPC y la Renta.

6.1.2. Requisitos No Funcionales (RNF)

Los requisitos no funcionales aseguran la calidad, fiabilidad y escalabilidad de la solución desarrollada:

- **RNF-01: Gobernanza y Fiabilidad del Dato:** Los datos de entrada deben proceder estrictamente de repositorios públicos oficiales (Open Data) para garantizar la validez estadística y la auditabilidad del modelo.
- **RNF-02: Consistencia Métrica (Única Fuente de la Verdad):** Los datos consumidos por el informe estático de Power BI y el modelo predictivo de Streamlit deben nacer del mismo dataset unificado (`house_data_gold.csv`), garantizando que no existan discrepancias en los resultados.
- **RNF-03: Interactividad y Usabilidad:** Las visualizaciones deben ser dinámicas, permitiendo al analista realizar drill-down desde una perspectiva nacional a una regional de forma fluida.
- **RNF-04: Interpretabilidad del Modelo:** El modelo de IA seleccionado debe permitir entender el "porqué" de las predicciones (explicabilidad), evitando modelos de "caja negra" que no aporten valor al diagnóstico social.

6.2. Descripción de las fuentes de datos

Para la realización de este proyecto se han seleccionado cuatro fuentes de datos oficiales y de alta fidelidad, provenientes principalmente del Instituto Nacional de Estadística (INE). La combinación de estos *datasets* permite cruzar variables de precios, inflación, capacidad adquisitiva y demografía.

6.2.1. Índice de Precios de Vivienda (IPV)

Este dataset es la columna vertebral del proyecto, ya que contiene la variable objetivo (target) de nuestro modelo de IA. El IPV mide la evolución de los precios de compraventa de las viviendas de precio libre en España.

- **Entidad emisora:** Instituto Nacional de Estadística (INE).
- **Granularidad:** Datos trimestrales y anuales por Comunidad Autónoma.

- **Variables clave:** Índice, Variación trimestral y Variación anual.
- **Utilidad:** Permite identificar los ciclos inmobiliarios y la inflación específica del sector vivienda.

--- 2. Dataset IPV (Vivienda) ---

	¿Total Nacional	Comunidades y Ciudades Autónomas	General, vivienda nueva y de segunda mano	Índice y tasas	Periodo	Total
0	Nacional	NaN	General	Índice	2025T3	183,389
1	Nacional	NaN	General	Índice	2025T2	178,184
2	Nacional	NaN	General	Índice	2025T1	171,296

Figura 3. Dataset IPV (Vivienda)

Fuente: Cuaderno Jupyter

Nota: El dato original venía con nombres de CCAA no normalizados y tipos de datos que requerían limpieza.

6.2.2. Índice de Precios de Consumo (IPC)

El IPC es un indicador que mide la evolución de los precios de los bienes y servicios consumidos por las familias residentes en España.

- **Entidad emisora:** INE.
- **Variables clave:** Índice general, grupos de consumo y tasas de variación.
- **Utilidad en el proyecto:** Se utiliza para calcular la **Renta Ajustada**, permitiendo conocer si el poder adquisitivo real de los ciudadanos sube al mismo ritmo que la vivienda.

--- 1. Dataset IPC ---

	¿Comunidades y Ciudades Autónomas	Grupos ECOICOP ver.2	Tipo de dato	Periodo	Total
0	Nacional	Índice general	Índice	2026M02	NaN
1	Nacional	Índice general	Índice	2026M01	100,836
2	Nacional	Índice general	Índice	2025M12	101,289

Figura 4. Dataset IPC

Fuente: Cuaderno Jupyter

6.2.3. Renta Media por Comunidad Autónoma

Este dataset proporciona información sobre la renta media anual por habitante y por hogar.

- **Entidad emisora:** Encuesta de Condiciones de Vida (INE).
- **Variables clave:** Renta media por persona, Renta media por hogar.
- **Utilidad en el proyecto:** Es el denominador fundamental para el cálculo del **Ratio de Esfuerzo**. Sin este dato, no podríamos determinar la accesibilidad real, solo el precio nominal.

--- 4. Dataset Renta CCAA ---

	¿Renta	Total Nacional	Comunidades y Ciudades Autónomas	Periodo	Total
0	Media	Total Nacional	NaN	2023	20.676
1	Media	Total Nacional	NaN	2022	19.160
2	Media	Total Nacional	NaN	2021	18.103

Figura 5. Dataset Renta CCAA

Fuente: Cuaderno Jupyter

6.2.4. Estadística del Padrón (Población por Edad)

Para analizar la presión demográfica, se han extraído datos del padrón municipal segmentados por grupos de edad.

- **Entidad emisora:** INE.
- **Segmentación realizada:**
 - Población Joven: 0 a 34 años (Demanda potencial de primera vivienda).
 - Población Adulta: 35 a 64 años (Mercado consolidado).
 - Población Senior: +65 años.
- **Utilidad en el proyecto:** Identificar si las zonas con mayor Ratio de Esfuerzo coinciden con las zonas de mayor concentración de jóvenes.

--- 3. Dataset Población ---

	¿Comunidades	Edad (grupos quinquenales)	Sexo	Periodo	Total
0	Total Nacional	Todas las edades	Total	1 de enero de 2022	47.475.420
1	Total Nacional	Todas las edades	Total	1 de enero de 2021	47.385.107
2	Total Nacional	Todas las edades	Total	1 de enero de 2020	47.450.795

Figura 6. Dataset Población

Fuente: Cuaderno Jupyter

6.2.5. Procesamiento y Calidad de Datos (Capa Silver)

Una vez ingeridos los datos en bruto, se procedió a una fase crítica de transformación para asegurar la integridad y comparabilidad de los *datasets*. Sin esta etapa, el análisis cruzado resultaría imposible debido a las inconsistencias de origen.

Normalización Estructural y de Nomenclatura:

- **Renombrado de columnas:** Se aplicó una nomenclatura técnica estandarizada a todos los datasets para facilitar las operaciones de unión.
- **Limpieza y Mapeo de CCAA:** Corrección ortográfica y unificación de nombres de regiones (eliminando discrepancias entre fuentes) para garantizar una integridad referencial total.
- **Normalización de etiquetas de control:** Estandarización de categorías internas para permitir filtrados precisos.

```

=== ANÁLISIS INICIAL: IPC ===
filas y columnas: (324800, 5)
valores nulos totales: 1118
tipos de datos:
CCAA      object
Grupo     object
Tipo_Dato object
Periodo   object
Total     object
dtype: object

```

	CCAA	Grupo	Tipo_Dato	Periodo	Total
0	Nacional	Índice general	Índice	2026M02	NaN
1	Nacional	Índice general	Índice	2026M01	100,836

Figura 7. Datos Brutos

Fuente: Cuaderno Jupyter

```

✅ Ortografía y nombres regionales normalizados.
LISTA DEFINITIVA DE REGIONES:
array(['Nacional', 'Andalucía', 'Aragón', 'Asturias', 'Baleares',
      'Canarias', 'Cantabria', 'Castilla-León', 'Castilla-La Mancha',
      'Cataluña', 'Valencia', 'Extremadura', 'Galicia', 'Madrid',
      'Murcia', 'Navarra', 'País Vasco', 'La Rioja', 'Ceuta', 'Melilla'],
      dtype=object)

```

Figura 8. Limpieza nombres regiones

Fuente: Cuaderno Jupyter

Enriquecimiento y Transformación:

- **Creación de grupos de edad:** Segmentación de los datos demográficos para aislar el comportamiento del sector joven (20-34 años), cumpliendo con el objetivo principal del proyecto.
- **Consolidación anual y cálculo de medias:** Transformación de datos con granularidad mensual o trimestral en promedios anuales consolidados para sincronizar todas las fuentes.

```

✅ Consolidación finalizada.
registros totales - ipc: 500 | ipv: 380
nulos detectados en rango 2008-2022 - ipc: 0 | ipv: 0

```

	CCAA	Año	Total
345	Madrid	2022	25.858
346	Madrid	2023	24.916
347	Madrid	2024	25.459
348	Madrid	2025	26.267
349	Madrid	2026	25.855

Figura 9. Consolidación anual

Fuente: Cuaderno Jupyter

Calidad y Consistencia del Dato:

- **Inspección de consistencia entre datasets:** Validación cruzada para asegurar que los periodos temporales y las regiones coincidan entre el IPV, IPC y Renta.
- **Normalización de valores numéricos:** Conversión de tipos de datos y ajuste de escalas para que las comparaciones estadísticas sean válidas.
- **Eliminación de redundancias:** Limpieza de registros duplicados o variables que no aportaban valor predictivo, optimizando el rendimiento del modelo de IA.

Análisis del Dataset Internacional: Procesamiento específico de los datos de la Unión Europea para establecer el marco comparativo (Benchmark) que se visualizará en Power BI.

```

✓ Valores redundantes eliminados.
valores únicos en ccaa: ['Media']
valores únicos en ue: ['Media']

```

Figura 10. Eliminación valores nulos y redundantes

Fuente: Cuaderno Jupyter

```

=== ANÁLISIS ESPECÍFICO: RENTA ESPAÑA-UE ===
filas y columnas: (80, 4)
valores nulos totales: 0

VALORES ÚNICOS EN ÁMBITO:
['España' 'Unión Europea']

tipos de datos técnicos:
Tipo_Renta    object
Ambito        object
Año           int64
Total         object
dtype: object

muestreo de datos:

```

	Tipo_Renta	Ambito	Año	Total
0	Media	España	2023	20.676
1	Media	España	2022	19.160
2	Media	España	2021	18.103
3	Media	España	2020	18.116
4	Media	España	2019	17.287

Figura 11. Verificación Renta UE

Fuente: Cuaderno Jupyter

6.2.6. Consolidación de la Tabla Maestra (Capa Gold)

En la última etapa de la arquitectura Medallion, se consolidan todas las fuentes en un dataset unificado (house_data_gold.csv). El valor diferencial de esta capa reside en la creación de **variables sintéticas** que permiten un diagnóstico mucho más preciso que el uso de datos brutos. Se han desarrollado tres métricas clave:

1. **Ratio de Esfuerzo:** Calculado como $(\text{Precio_Vivienda_IPV} / \text{Renta_Media}) * 1000$. Esta métrica es el pilar del diagnóstico social del proyecto, ya que relaciona el coste de la vivienda con la capacidad económica real.
2. **Renta Ajustada al IPC:** Permite visualizar la evolución del poder adquisitivo real frente a la inflación, deflactando la renta media para observar si el crecimiento económico de los hogares es real o nominal.
3. **Porcentaje de Población Joven (Pct_Pob_Joven):** Métrica que calcula el peso relativo del segmento de 0 a 34 años sobre el total de la población. Pensada para contextualizar la presión demográfica en las zonas con precios más tensionados.

	CCAA	Año	Ratio_Esfuerzo	Renta_Ajustada_IPC	Pct_Pob_Joven
0	Andalucía	2008	9.707338	18458.754949	54.115681
1	Andalucía	2009	9.043424	20927.404943	53.618103
2	Andalucía	2010	9.052289	19262.952538	52.883452
3	Andalucía	2011	9.051540	17281.545688	52.130720
4	Andalucía	2012	7.935703	17247.484735	51.269749

Figura 12. Variables Creadas

Fuente: Cuaderno Jupyter

✓ Capa Gold finalizada: Tabla maestra lista para el análisis.

	CCAA	Año	Indice_IPC	Precio_Vivienda_IPV	Renta_Media	Pob_Adulta	Pob_Joven	Pob_Senior
0	Andalucía	2008	19.684	134.534	13859	2574931.0	4438185.0	1188176.0
1	Andalucía	2009	18.031	130.162	14393	2634400.0	4451302.0	1216162.0
2	Andalucía	2010	19.261	128.108	14152	2701489.0	4426208.0	1242044.0
3	Andalucía	2011	20.192	120.476	13310	2760619.0	4390823.0	1271275.0
4	Andalucía	2012	20.355	106.267	13391	2824494.0	4331476.0	1292435.0
5	Andalucía	2013	20.020	96.923	12705	2870332.0	4257795.0	1310452.0
6	Andalucía	2014	19.405	97.077	12118	2894215.0	4179370.0	1326811.0
7	Andalucía	2015	19.428	100.000	11862	2928388.0	4118941.0	1349621.0
8	Andalucía	2016	19.476	102.842	12560	2965534.0	4062793.0	1357646.0
9	Andalucía	2017	20.457	106.101	13709	2989295.0	4013550.0	1374723.0

Figura 13. Dataset Final

Fuente: Cuaderno Jupyter

Nota: En esta captura se observa cómo los datos ya están perfectamente estructurados, etiquetados y listos para ser consumidos por el EDA y el modelo de IA.

6.4. Análisis Exploratorio Visual (EDA)

Tras la consolidación del dataset Gold, se ha procedido a una fase de exploración visual para validar las hipótesis del proyecto. El objetivo es transformar las filas y columnas en conocimiento accionable, identificando patrones de tensión inmobiliaria y pérdida de poder adquisitivo a distintas escalas.

6.4.1. Contexto Internacional: España vs. Unión Europea




Figura 14. Gráfico Líneas España/UE

Fuente: Cuaderno Jupyter

"Figura 15. Comparativa histórica de renta España vs. Unión Europea. El gráfico ilustra la brecha de crecimiento y estabilización de la rotura, justificando la necesidad de hacer un drill-down para la economía española. La visualización ampliada y detallada de esta comparativa se encuentra disponible en el **Anexo 12.4 (Figura 15).**"

- **Descripción:** Se observa que, aunque la renta media en España sigue una tendencia creciente, existe una brecha persistente respecto a la media de la Unión Europea.
- **Hallazgo:** La gráfica de barras ("La Brecha Real") evidencia que desde 2012 la distancia no ha dejado de aumentar, situándose por encima de los 2.000€ anuales de diferencia. Este es el **punto de partida** que justifica la necesidad de analizar por qué, con rentas menores que nuestros vecinos europeos, el precio de la vivienda en España sigue tensionado.

6.4.2. Disparidad Regional y Poder Adquisitivo




Figura 16. Evolución Renta por CCAA

Fuente: Cuaderno Jupyter

"Figura 17. Distribución geográfica de la Renta Disponible por Comunidad Autónoma. La visualización mediante un mapa de calor en escala de azules permite identificar las disparidades económicas regionales, siendo esta una de las variables con mayor peso predictivo en el modelo. La imagen ampliada en alta resolución se encuentra disponible en el **Anexo 12.4 (Figura 17).**"

- **Descripción:** El análisis desciende al nivel autonómico para identificar las asimetrías internas del país.
- **Hallazgo:** El ranking muestra una polarización extrema: mientras País Vasco, Navarra y Madrid lideran los niveles de renta, regiones como Canarias y Andalucía se sitúan en la parte baja con diferencias salariales bruscas en el territorio.

6.4.3. El Indicador Crítico: Ratio de Esfuerzo y Demografía




Figura 18. Mapa Ratio Esfuerzo CCAA

Fuente: Cuaderno Jupyter

"Figura 19. Correlación entre Población Joven, Ratio de Esfuerzo por Comunidad Autónoma. Este gráfico de dispersión, representado en tonalidades rojas, permite analizar de forma simultánea si la demografía joven afecta a la tensión de los precios. La distribución de los puntos facilita la detección de provincias con mercados especialmente tensionados. La visualización técnica completa se encuentra en el **Anexo 12.4 (Figura 19).**"

- **Descripción:** Se visualiza la métrica propia creada en la capa Gold para geolocalizar la emergencia en los territorios españoles.
- **Hallazgo:** El análisis mediante el mapa de **Ratio de Esfuerzo** confirma que el problema no reside únicamente en los "precios altos", sino en la debilidad de las **rentas locales**. Al observar el *Scatter Plot*, se evidencia que no existe una correlación lineal directa entre el volumen de población joven y el aumento de precios; de hecho, regiones con alta densidad joven como Madrid o Cataluña muestran un esfuerzo más contenido gracias a sus niveles salariales. El verdadero riesgo de exclusión se localiza donde la presencia de población joven coincide con **rentas bajas y precios tensionados**, validando que la renta es la variable con mayor peso específico en la crisis de accesibilidad.

6.4.4. Distribución de Datos y Densidad (Violin Plot)




Figura 20. Evolución Dispersión Ratio Esfuerzo

Fuente: Cuaderno Jupyter

- Descripción:** Se ha generado un gráfico de violín centrado exclusivamente en la métrica `Ratio_Esfuerzo`. Esta visualización combina la potencia de un diagrama de caja (para ver medianas y cuartiles) con la curva de densidad de probabilidad, permitiendo observar cómo se distribuye la tensión inmobiliaria entre las distintas regiones y años del estudio.
- Hallazgo:** La gráfica revela una gran concentración de datos en la parte media (indicando una situación de relativa tensión en gran parte del territorio), pero muestra una **"atenuación" o cuello alargado** hacia valores altos. Esto confirma estadísticamente que la crisis de accesibilidad es un fenómeno generalizado por igual, que está impulsado por regiones con comportamientos extremos (outliers) que bajan la media nacional.

6.5 Diagnóstico Estadístico (Matriz de Correlación)

Tras el exhaustivo Análisis Exploratorio de Datos (EDA), se han validado las hipótesis planteadas al inicio del proyecto. La conclusión principal es que la crisis de acceso a la vivienda en España es un fenómeno multifactorial:




Figura 21. Matriz de Correlación

Fuente: Cuaderno Jupyter

- **La Variable Crítica de la Renta ($r = -0.63$):** Se detecta una correlación negativa fuerte entre la **Renta Media** y el **Ratio de Esfuerzo**. Este dato confirma que el estrés habitacional en España está inversamente ligado a la capacidad económica local: a menor renta media, mayor es el esfuerzo necesario para acceder a la vivienda. Esto justifica el peso prioritario de la renta en el modelo predictivo.
- **Vector de Encarecimiento del Activo ($r = 0.54$):** Existe un vínculo positivo alto entre el **IPV** y el **Ratio de Esfuerzo**. Es una relación lógica, ya que el encarecimiento del precio de la vivienda es el motor directo que empuja al alza el indicador de esfuerzo.

- **Desacoplamiento Salarial ($r = 0.29$):** La correlación positiva pero baja entre la **Renta Media** y el **IPV** evidencia el problema estructural del país: los salarios no acompañan el ritmo de crecimiento del mercado inmobiliario, ensanchando la brecha de accesibilidad año tras año.
- **Independencia del Mercado Inmobiliario ($r = 0.13$):** La baja correlación entre el **IPV** y el **IPC** general sugiere que el sector inmobiliario se rige por dinámicas propias (oferta, demanda y especulación) que exceden la inflación común de la cesta de la compra.
- **Neutralidad Demográfica ($r = 0.04$):** El volumen de **Población Joven** muestra una correlación casi nula por sí sola. Esto valida que la presión demográfica no altera el mercado de forma lineal, sino que su impacto es una consecuencia de la interacción con la precariedad salarial de cada región.

6.6 Conclusiones del Análisis y Clasificación de Riesgo

Tras el procesado de las fuentes de datos y la aplicación de las métricas sintéticas en la capa **Gold**, se ha procedido a categorizar las regiones según su nivel de vulnerabilidad. Esta clasificación no solo atiende al precio nominal de la vivienda, sino a la relación crítica entre el coste de vida y la capacidad de renta local, permitiendo identificar las siguientes prioridades de intervención

6.6.1. Ranking de Emergencia por CCAA

"**Tabla 1. Ranking de emergencia por Comunidad Autónoma.** Se presenta una selección de las regiones con gran tensión en el mercado inmobiliario (Canarias, Andalucía, Baleares, Madrid y Cataluña), analizadas bajo criterios de accesibilidad y esfuerzo financiero. El desglose completo de los indicadores y la metodología de puntuación para este ranking se detallan en el **Anexo 12.3 (Tabla Ranking de Emergencia)**."

6.6.2. Casos de Uso del Proyecto

El ecosistema integrado (**Dataset Gold + Dashboard + Motor Predictivo**) ha sido diseñado para ofrecer valor en tres vertientes estratégicas:

- **Planificación Institucional y Social:** Permite a organismos públicos geolocalizar regiones donde la población enfrenta un riesgo crítico de exclusión habitacional, optimizando la asignación de ayudas y políticas de vivienda.
- **Asesoramiento al Ciudadano/Comprador:** Actúa como una herramienta de transparencia para la población, permitiendo identificar zonas donde existe un equilibrio real entre el precio del inmueble y el nivel salarial de la región.
- **Simulación Prospectiva (What-if):** Gracias al motor de IA y la interfaz de Streamlit, el usuario puede proyectar escenarios macroeconómicos, como variaciones en el IPC o estancamientos salariales.

7. Diseño del proyecto

(6-14 páginas)

En este capítulo se detalla la arquitectura técnica y el diseño lógico de la solución propuesta. El diseño se ha estructurado para garantizar que el flujo de datos sea íntegro, desde su captación hasta la generación de predicciones mediante Inteligencia Artificial.

7.1. Diseño de la Arquitectura de Datos (Medallion Architecture)

"Figura 22. Diagrama de la Arquitectura Medallion y Flujo de Datos del Proyecto."

Ciclo de vida del dato desde su origen en archivos CSV (INE) hasta su explotación final. Se detalla la transición por las tres capas de procesamiento (Bronce, Plata y Oro) y su integración con la capa de aplicación, que alimenta tanto el Dashboard de Power BI como la App de predicción en Streamlit. **Anexo 12.4 (Figura 22).**

La solución técnica se despliega bajo una Arquitectura Medallion, un estándar de ingeniería de datos que garantiza la integridad mediante un flujo de refinamiento progresivo. El sistema se articula en dos pilares críticos:

- **Trazabilidad Extremo a Extremo:** El diseño asegura que cualquier métrica visualizada en el dashboard o cualquier predicción de la IA pueda auditarse hasta su origen en la capa Bronze (datos brutos del INE).
- **Consistencia de Datos (Single Source of Truth):** Tanto el informe de Power BI como el modelo de Gradient Boosting consumen exclusivamente el dataset consolidado en la capa Gold, garantizando que no existan discrepancias en los resultados finales.

7.1.1. Capa Bronze (Raw Data)

El diseño contempla una zona de aterrizaje donde los datasets originales del INE y Eurostat (IPC, IPV, Renta, Población y Renta UE) se almacenan en su formato **CSV nativo**. La prioridad absoluta en esta capa es la preservación de la **"fuente de la verdad"** sin alteraciones, permitiendo volver al dato original en caso de requerir un re-procesamiento completo del pipeline .

7.1.2. Capa Silver (Cleaned Data)

En esta fase se ejecutan las transformaciones críticas para convertir datos heterogéneos en información compatible. El diseño de esta capa incluye:

- **Normalización Estructural:** Renombrado de columnas, mapeo y corrección ortográfica de las 17 CCAA y estandarización de etiquetas de control.
- **Consistencia y Calidad:** Conversión de tipos de datos (casting), eliminación de registros redundantes e inspección de consistencia entre series temporales.
- **Enriquecimiento Base:** Consolidación anual de medias y creación de segmentos demográficos (grupos de edad), alineando el dataset internacional con el nacional para su posterior comparativa.

7.1.3. Capa Gold (Business Logic)

La capa final consiste en el diseño de la **Tabla Maestra (Dataset Gold)**. Representa el valor añadido del proyecto. Esta capa se diseña como el punto de entrega unificado (Single Source of Truth), optimizada para ser consumida garantizando que no existan discrepancias en los resultados.


```
# UNIÓN DE DATASETS (CAPA GOLD)

# 1. unimos ipc con ipv (vivienda) usando suffixes para distinguir los totales
df_union = pd.merge(ipc, ipv, on=['CCAA', 'Año'], suffixes=('_IPC', '_IPV'))

# 2. añadimos la renta (dimensiones: ccaa, año y total)
df_union = pd.merge(df_union, renta_ccaa[['CCAA', 'Año', 'Total']], on=['CCAA', 'Año'])

# 3. añadimos la población segmentada por grupos de edad
df_final = pd.merge(df_union, poblacion, on=['CCAA', 'Año'])

# 4. NORMALIZACIÓN DE NOMENCLATURA PROFESIONAL
df_final.columns = [
    'CCAA', 'Año', 'Indice_IPC', 'Precio_Vivienda_IPV', 'Renta_Media',
    'Pob_Adulta', 'Pob_Joven', 'Pob_Senior'
]

# 5. ORDENACIÓN Y LIMPIEZA DE ÍNDICE
df_final = df_final.sort_values(['CCAA', 'Año']).reset_index(drop=True)

print("✅ Capa Gold finalizada: Tabla maestra lista para el análisis.")
display(df_final.head(10))
```

Figura 23. Código Merge Dataset Final

Fuente: Cuaderno Jupyter

Nota: La imagen muestra la creación de la tabla maestra mediante un inner join basado en la clave compuesta ['CCAA', 'Año']. Este diseño garantiza la alineación exacta de los indicadores económicos y demográficos, eliminando registros incompletos y asegurando un dataset robusto para el entrenamiento del modelo de IA.

7.2. Diseño del Almacenamiento y Estructura de Datos

7.2.1. Modelo de Datos Desnormalizado

A diferencia de las bases de datos relacionales tradicionales (donde la información se divide en muchas tablas para ahorrar espacio), el diseño de este proyecto apuesta por un **modelo desnormalizado**. Esto significa que hemos diseñado una "Tabla Maestra" donde cada registro (fila) es una unidad de información completa.

- **Justificación:** Este diseño reduce la carga computacional durante el entrenamiento de la IA, ya que el algoritmo no tiene que realizar uniones (joins) en tiempo de ejecución.

7.2.2. Diccionario de Datos (Diseño de la Capa Gold)

Para asegurar que el sistema es escalable, se ha definido el siguiente esquema técnico para el archivo `house_data_gold.csv`:

"Tabla 2. Especificación técnica del dataset final (Capa Gold)." En esta tabla se detalla la estructura del Data Frame utilizado para el Power BI y entrenamiento del modelo. El diccionario completo con tipos de datos y métodos de cálculo se encuentra en el **Anexo 12.3 (Tabla 2)**.

7.2.3. Estrategia de Interoperabilidad

El uso del formato **CSV con codificación UTF-8-SIG** no es casual. Se ha diseñado así para garantizar que caracteres especiales (como las tildes en "Aragón" o "Castilla y León") no se corrompan al saltar de **Python** (Linux/Unix friendly) a **Power BI** (Windows friendly), evitando errores de encoding que suelen arruinar los procesos de Big Data.

7.3 Algoritmo

7.3.1. Selección del Algoritmo: Hist Gradient Boosting Regressor

Se ha optado por este modelo de Ensemble Learning (basado en árboles de decisión) en lugar de una regresión lineal simple.




Figura 24. Modelo Hist Gradient Boosting Regressor

Fuente: Internet

Aprendizaje Iterativo: Como muestra la imagen, el sistema genera un primer modelo sencillo (E_0) y calcula su error. Los modelos siguientes (E_1, E_2...) se diseñan específicamente para corregir los fallos del anterior.

Captura de Interacciones: El modelo no asume que "si sube la renta, sube el precio" de forma fija. Es capaz de entender que, por ejemplo, una subida del IPC afecta de forma distinta en Madrid que en Extremadura, algo que una fórmula matemática simple de Betas no podría detectar.

Robustez: Al trabajar con "Histogramas" (de ahí el nombre Hist), el diseño es extremadamente rápido y eficiente con los datos de series temporales del INE.

7.3.2. Arquitectura de Entrenamiento (Pipeline)

El diseño del aprendizaje no se basa en una división estática, sino en un **Protocolo de Validación Cruzada Temporal** (Time Series Split).

- **Diseño de Ventanas Móviles:** El sistema se ha entrenado mediante 5 iteraciones temporales (folds), donde el modelo aprende de un bloque de años y se evalúa en el año inmediatamente posterior. Esto garantiza que la IA no sufra de "sesgo de mirada al futuro".
- **Ingeniería de Características (Lagging):** Se ha diseñado una variable de retardo (lag) donde el IPV del año previo actúa como predictor. Además, se ha creado la variable sintética "**Renta Ajustada al IPC**" para que el modelo entienda el poder adquisitivo real, no solo el nominal.
- **Regularización L2:** Para evitar el sobreajuste (overfitting), el diseño incorpora una penalización L2 que suaviza la influencia de variables excesivamente volátiles.

7.3.3. Conclusiones del Modelo Predictivo y Validación Estadística

Tras someter la arquitectura al protocolo de validación temporal, los resultados consolidan la viabilidad del modelo para la simulación de escenarios económicos:

- **Precisión del Modelo (MAE: 6.58):** El modelo presenta un Error Absoluto Medio de **6.58 puntos** sobre el índice IPV. Teniendo en cuenta que el índice se mueve en rangos superiores a los 100-150 puntos en años recientes, un error de solo 6 puntos indica una desviación mínima. Esto permite que las simulaciones en la interfaz de Streamlit tengan una **validez práctica alta** para el ciudadano.
- **Poder Predictivo (R^2 : 0.7331):** El coeficiente de determinación global del **73.31%** es el dato más relevante. Indica que la combinación de variables macroeconómicas (IPC, Renta) junto con el componente auto-regresivo (IPV del año anterior) logra capturar la gran mayoría de la tendencia del mercado inmobiliario español.
- **Estabilidad en la Validación (Folds):** Como se observa en las cinco iteraciones temporales, el modelo mantiene una consistencia notable, con un R^2 que oscila entre el 0.77 y el 0.84. Esta estabilidad demuestra que el diseño es **robusto** y que el algoritmo de Gradient Boosting no sufre de sobreajuste (*overfitting*) ante los cambios de ciclo económico.
- **Interpretación de la IA:** A diferencia del modelo base inicial, esta arquitectura demuestra que el precio de la vivienda en España tiene una fuerte **dependencia inercial** y una respuesta clara a la capacidad adquisitiva real (Renta Ajustada). El 27% de varianza no explicada se atribuye a factores exógenos fuera del alcance del dataset, como la política de tipos de interés del BCE o la escasez de oferta de obra nueva, leyes territoriales, inversión extranjera, grandes tenedores.

Validación Final del Diseño: Los resultados confirman que la arquitectura propuesta es apta para su despliegue en la capa de aplicación. El modelo no solo sigue la tendencia general, sino que tiene la precisión suficiente para actuar como un motor de decisión en el dashboard interactivo



Figura 25. Conclusiones Modelo IA

Fuente: Cuaderno Jupyter

7.4. Diseño de la Interfaz de Usuario y Visualización

El diseño de la capa de salida se ha dividido en dos herramientas complementarias, buscando cubrir tanto el análisis descriptivo profundo como la simulación predictiva ágil.

7.4.1. Dashboard de Inteligencia de Negocio (Power BI)

El diseño del panel en Power BI se ha estructurado bajo una jerarquía visual de alta densidad informativa, permitiendo al usuario una transición intuitiva desde los indicadores macro hasta el detalle regional.

- **KPIs de Control Superior:** Se han diseñado seis tarjetas de indicadores clave (Seniors) que muestran de forma inmediata el Ratio de Esfuerzo medio (7.16), el Precio de la Vivienda (126.11) y la Renta Ajustada, permitiendo una lectura rápida del estado del mercado al filtrar por año o comunidad.
- **Geolocalización mediante Mapa de Burbujas:** El diseño incluye un mapa de España donde el tamaño de las burbujas representa el **Promedio de Precio de Vivienda (IPV)** por región. Esta visualización permite identificar instantáneamente los "puntos calientes" del mercado (como Madrid, Cataluña o Baleares), destacando geográficamente las diferencias de coste de vida y permitiendo al

usuario detectar patrones espaciales que los gráficos de barras no muestran con tanta claridad.

- **Análisis de Correlación Dinámica (Scatter Plot):** El diseño incluye un gráfico de dispersión (abajo a la izquierda) que cruza el Precio de la Vivienda vs. Renta Media. Esto permite visualizar visualmente clústeres de CCAA; por ejemplo, identificando regiones con rentas similares pero precios de vivienda desproporcionados.
- **Distribución de Población (Treemap):** Se ha integrado un gráfico de jerarquía para la Suma de Población Adulta, donde el tamaño de los rectángulos (Andalucía, Cataluña, Madrid, etc.) permite ponderar la relevancia demográfica de cada región en el análisis global.
- **Segmentación Temporal y Geográfica (Slicers):** El diseño incorpora una matriz de botones para la selección de años (2008-2023) y filtros por CCAA, lo que dota al dashboard de una capacidad de análisis comparativo "en caliente" (Live Analysis).
- **Visualización de Tendencias y Ratios:** Se incluyen gráficos de barras para el Ratio de Esfuerzo por CCAA, ordenados de mayor a menor (destacando Ceuta, Baleares y Andalucía como zonas de alta tensión), facilitando la identificación de áreas prioritarias para la planificación institucional.

7.4.2. Aplicación de Simulación y Predicción (Streamlit)

A diferencia del análisis histórico del dashboard, la interfaz diseñada en Streamlit permite la interactividad directa con el motor de IA.

- **Arquitectura de Entrada (Sidebar):** El diseño contempla una barra lateral con controles deslizantes (*sliders*). Estos permiten al usuario "jugar" con variables hipotéticas sobre el escenario del año anterior:
 - ¿Qué pasaría con el precio de la vivienda si la inflación (IPC) sube un 5% adicional?
 - ¿Cómo compensaría una subida de la renta media del 3% en mi comunidad?

- **Visualización de Resultados:** El diseño incluye una tarjeta de visualización de KPI que muestra la predicción en tiempo real. Se ha optado por una **Interfaz Minimalista (UI)** para que el foco esté en el valor numérico generado por el algoritmo de Boosting, acompañado de una comparativa con el valor real del año anterior.

"**Tabla 3. Segmentación de usuarios potenciales y casos de uso del sistema.** Se definen tres perfiles estratégicos que validan la versatilidad de la herramienta. Cada perfil utiliza las capacidades de predicción y visualización del sistema para reducir la incertidumbre y entender el pasado. El detalle de las necesidades, objetivos y beneficios por perfil se describe en el **Anexo 12.3 (Tabla 3).**"

7.5. Diseño del Flujo de Ejecución y Control de Errores

Para garantizar la estabilidad de la solución, se ha diseñado un flujo de procesos lógico que asegura que cada componente reciba la información en el formato y tiempo correctos.

7.5.1. Ciclo de Vida de la Inferencia

El diseño del flujo se divide en cuatro estadios críticos que ocurren cada vez que el sistema se ejecuta:

1. **Carga del Pipeline:** El sistema carga el archivo `modelo_ipv_v2.pkl` que contiene tanto el preprocesador (OneHotEncoder) como el regresor entrenado.
2. **Validación de Entrada:** Se ha diseñado un control que captura los valores de los *sliders*. Si el usuario selecciona una combinación de datos atípica, el modelo de Boosting la gestiona mediante sus nodos terminales sin necesidad de re-escalar los datos manualmente.
3. **Inferencia de IA:** El motor **Hist Gradient Boosting** recibe las 6 variables (incluyendo la variable de retardo `IPV_Anterior`) para generar la predicción.
4. **Renderizado Dinámico:** Streamlit traduce el vector numérico en un elemento visual de alto impacto para el usuario.

7.5.2. Diseño de la Persistencia y Disponibilidad

Este proyecto se ha diseñado bajo el principio de **"Portable Data & Edge AI"**:

- **Contenedores de Modelo:** Al exportar el pipeline completo en formato binario serializado (.pkl) mediante la librería **Joblib**, la lógica de la inferencia de la IA es completamente independiente del código de entrenamiento.
- **Eficiencia en Memoria:** El diseño está optimizado para cargar un volumen reducido de datos del Dataset Gold, garantizando que la aplicación sea extremadamente rápida, ligera en su ejecución y viable para dispositivos con recursos limitados.

8. Despliegue y pruebas

(4-10 páginas)

En este capítulo se valida el funcionamiento técnico de la solución y se analizan los resultados obtenidos tras el despliegue del ecosistema de datos. Se comprueba que el modelo de IA y las interfaces visuales operan de forma coordinada y precisa.

8.1. Tabla Resumen de Pruebas Ejecutadas

Para ofrecer una visión global del estado del proyecto, se presenta la siguiente matriz de pruebas:

"Tabla 4. Pruebas de calidad del sistema. Con el objetivo de garantizar la fiabilidad del ecosistema integrado (Datos - IA - Interfaz), se ha ejecutado un plan de pruebas estructurado. El desglose detallado de los casos de prueba, criterios de aceptación y resultados obtenidos se encuentra en el **Anexo 12.3 (Tabla 4).**"

8.2. Validación de Integridad Estructural (Capa Gold)

Objetivo: Garantizar que el proceso de integración de datos (*Data Merging*) no ha generado valores perdidos que puedan sesgar el entrenamiento del modelo de Inteligencia Artificial.

- **Descripción de la Prueba:** Se ha implementado un script de auditoría al final de la Fase 3(Gold). Mediante el uso combinado de las funciones `.isnull()` y `.sum()`.
- **Resultado Obtenido:** **0 valores nulos** en el dataset final (2008-2022).
- **Valoración:** Se confirma que la serie histórica es robusta. El éxito de esta prueba confirma que el filtrado realizado en la Capa Silver fue efectivo y que la unión de las tablas fue exacta, manteniendo la coherencia de la serie histórica.

```

✅ TEST PASADO: El dataset consolidado no contiene valores nulos.
CCAA          0
Año           0
Indice_IPC    0
Precio_Vivienda_IPV  0
Renta_Media   0
Pob_Adulta    0
Pob_Joven     0
Pob_Senior    0
Ratio_Esfuerzo  0
Renta_Ajustada_IPC  0
Pct_Pob_Joven  0
dtype: int64

```

Figura 26. Comprobación Valores Nulos

Fuente: Cuaderno Jupyter

8.3. Pruebas de Interfaz de Usuario e Inferencia (Streamlit)

Este apartado valida que la herramienta es funcional para un usuario no técnico y que el modelo de IA responde correctamente en el entorno web.

- **Objetivo:** Verificar la correcta carga del modelo de alta precisión (**Gradient Boosting**) mediante el archivo **.pkl** y la interactividad de los controles deslizantes (sliders).
- **Procedimiento:** Ejecución de la aplicación mediante el comando **'streamlit run'**. Se introducen valores en la barra lateral para observar el cambio en tiempo real del KPI de predicción.
- **Resultado:** El sistema procesa los inputs de forma inmediata. A diferencia de modelos lineales, el uso de **Gradient Boosting** permite que la aplicación gestione mejor los valores extremos introducidos por el usuario, devolviendo predicciones que respetan la tendencia histórica de la comunidad seleccionada.



Figura 27. Menu App con IPV

Fuente: App Streamlit

8.4. Verificación Visual y de Lógica de Interfaz

Este apartado valida la experiencia del usuario y la respuesta inmediata del sistema ante la manipulación de variables.

- **Componentes Visuales:** El simulador presenta un panel de control basado en *sliders* que permiten ajustar la Renta, el IPC y la Demografía Joven. La respuesta es instantánea, actualizando un panel de "Cards" superiores que muestran el IPV proyectado, el porcentaje de variación y el nivel de riesgo.
- **Sistema de Alertas:** Se ha implementado un código de colores en las métricas.
 - **Verde:** Indica una proyección de estabilidad o crecimiento moderado acorde a los fundamentales.
 - **Rojo:** Se activa automáticamente cuando la proyección de la IA sugiere que el precio entrará en zona de máximos históricos o sobrecalentamiento, actuando como una alerta de riesgo para el inversor.

- **Interactividad Gráfica:** Debajo de las métricas, un gráfico dinámico compara el último dato histórico (2022) con la predicción actual, permitiendo al usuario visualizar la magnitud del cambio de forma intuitiva.




Figura 28. Aviso Simulador

Fuente: App Streamlit

8.5. Validación Estratégica: Cotejo 2023 y Escenarios de Control

En esta sección se somete al modelo a una prueba de fuego doble: la precisión con datos reales y la coherencia lógica en situaciones extremas.

8.5.1 Cotejo con Datos Reales (Backtesting 2023)

Se introdujeron los datos macroeconómicos reales de cierre de 2023 para validar la precisión del modelo en entornos de mercado conocidos.

CCAA	IPV Real 2023	Predicción IA	Error Absoluto	Interpretación
Andalucía	143,57	146,89	3,32 pts	Alta precisión en tendencia alcista.
C. Valenciana	135,92	140,35	4,43 pts	Captura el dinamismo del arco mediterráneo.

Tabla 5. Cotejo Datos 2023

Fuente: Elaboración Propia

Análisis de Error: El error absoluto medio en este cotejo real se mantiene por debajo de los 4.5 puntos, lo cual es coherente con el **MAE global de 6.58** obtenido durante la validación cruzada. Esto indica que el modelo no solo memoriza el pasado, sino que es capaz de inferir la dirección del mercado con gran exactitud.




Figura. 29. Validación de neutralidad en Cataluña

Fuente: App Streamlit

8.5.2. Test de Estrés y Sensibilidad: El caso de Extremadura

Para confirmar que el modelo no se limita a repetir la inercia histórica, se ha sometido a Extremadura a dos escenarios económicos artificiales. Partiendo de una situación base de **117.57 puntos** (proyección con datos actuales), los resultados fueron los siguientes:

Escenario A: "Expansión Económica Agresiva" (Optimismo)

- **Variables:** Se simula un incremento de la Renta Media hasta los **21.000 €** (aprox. +40%) y se mantiene un IPC controlado en **25.00**.
- **Resultado:** El modelo responde con un salto brusco en el IPV proyectado, superando los **121.92 puntos**.
- **Conclusión:** La IA identifica una alta **elasticidad-renta** en esta región. Al detectar que los precios de partida son bajos en comparación con la media nacional, el algoritmo "permite" crecimientos agresivos cuando el poder adquisitivo de los ciudadanos aumenta, validando Extremadura como un mercado con alto potencial de revalorización bajo condiciones favorables.

"Figura 30. Simulación de proyecciones en la interfaz Streamlit (Caso: Mercado de Extremadura). La imagen muestra la capacidad de respuesta de la aplicación ante la entrada de nuevos parámetros. En este escenario, el sistema procesa una tendencia al alza del IPV en la región de Extremadura, realizando la inferencia en tiempo real y actualizando las visualizaciones de soporte para el usuario. El detalle del flujo de navegación y las capturas de alta resolución de la simulación se encuentran disponibles en el **Anexo 12.4 (Figura 30)**."

Escenario B: "Estanflación y Pérdida de Poder Adquisitivo" (Crisis)

- **Variables:** Se simula una caída de la Renta Media hasta los **12.000 €** y un escenario de hiperinflación con un IPC del **35.00**.
- **Resultado:** El modelo frena drásticamente la tendencia alcista, haciendo retroceder el IPV hacia valores cercanos al **114 puntos** (variación casi nula respecto a la base).
- **Conclusión:** Este test es el más crítico, ya que demuestra la **sensibilidad al riesgo**. A diferencia de modelos más rígidos, este algoritmo es capaz de proyectar correcciones cuando los fundamentales económicos se deterioran. La

IA "entiende" que, aunque la tendencia histórica sea estable, una renta insuficiente combinada con una inflación alta imposibilita el mantenimiento de los precios actuales.

"Figura 31. Detección de cambio de tendencia y estabilización del IPV. A diferencia del escenario previo, esta captura muestra la capacidad del modelo para identificar puntos de inflexión y estabilización en el mercado inmobiliario. La visualización permite contrastar cómo el algoritmo ajusta las predicciones cuando las variables macroeconómicas sugieren un enfriamiento de los precios. La comparativa visual completa y el análisis de la desviación en este escenario se encuentran en el **Anexo 12.4 (Figura 31).**"

8.5.3. Identificación de sesgos en mercados de alta tensión (Caso Baleares)

Tras someter al modelo a los datos de las **Islas Baleares**, se observa una de las desviaciones más interesantes del estudio. Mientras que el IPV real de 2023 escaló hasta los **163.44**, el modelo proyecta un valor sensiblemente inferior (**157.03**).

"Figura 32. Análisis de tendencia divergente en el mercado balear. Se presenta un escenario de simulación específico para las Islas Baleares, donde el modelo captura una dinámica de mercado contrapuesta a la predicción. La captura detallada se encuentra en el **Anexo 12.4 (Figura 32).**"

¿Por qué ocurre esto? Análisis técnico:

- **Desconexión con la Renta Local:** El modelo basa su aprendizaje en la capacidad de compra del ciudadano medio (Renta Media). Sin embargo, el mercado balear está fuertemente distorsionado por la **inversión extranjera y el capital foráneo**, cuyo poder adquisitivo no queda reflejado en las estadísticas de renta regionales.
- **Factor de Escasez:** La IA procesa variables económicas, pero no puede "ver" que Baleares es un territorio limitado (islas) donde la oferta es rígida, lo que permite que los precios suban incluso cuando la lógica económica de rentas locales sugiere un techo.

- **Efecto de "Techo de Cristal":** Al haber alcanzado niveles de IPV extremos en comparación con el resto de España, la IA aplica una lógica de prudencia, interpretando que el mercado está en zona de **sobrecalentamiento**.

8.6 Dashboard Histórico

El Dashboard utiliza directamente el archivo realizado en la **Capa Oro** de nuestra arquitectura Medallion, garantizando que los datos visualizados son veraces y están limpios. Se han implementado segmentadores por Comunidad Autónoma y rangos temporales para permitir al analista navegar por la serie histórica (2008-2022).




Figura 33. Dashboard Histórico

Fuente: Elaboración Propia

8.6.1. Indicadores Clave de Rendimiento (KPIs)

- **Ratio de Esfuerzo (6,88):** Media nacional que marca el umbral de accesibilidad.
- **Promedio IPV (121,21):** Nivel actual de precios comparado con el año base.
- **Promedio Renta (17,940 mil):** Renta media de la comunidad.
- **Renta Ajustada 2022 (23,48 mil):** El poder adquisitivo real tras aplicar el deflactor del IPC.
- **Población Joven (21,11 mill.):** Volumen acumulado de demanda potencial en el periodo analizado.

- **Promedio IPC (20,04):** Promedio IPC en escala 1:5

8.6.2. Desglose Visual y Distribución Geográfica

El cuerpo central del panel organiza la información mediante cinco visualizaciones estratégicas:

1. **Mapa de Burbujas (Centro-Izquierda):** Representa el IPV por comunidad. El tamaño de la burbuja permite identificar visualmente el peso del precio en regiones como Madrid, Cataluña o Baleares en el año seleccionado (2020 en la captura).
2. **Gráfico de Barras Temporal (Centro):** Muestra la evolución del precio por año y región, facilitando la comparación directa entre comunidades.
3. **Ranking de Ratio de Esfuerzo (Derecha):** Un gráfico de barras ordenado de mayor a menor que sitúa a Ceuta, Andalucía y Extremadura como puntos de alta tensión en relación a sus rentas.
4. **Scatter Plot de Correlación (Inferior-Izquierda):** Cruza el IPV con la Renta Media. Es fundamental para detectar anomalías: comunidades con rentas similares pero precios de vivienda muy dispares.
5. **Treemap de Población Adulta (Inferior-Derecha):** Clasifica las CCAA por volumen de población en edad laboral. El tamaño de los rectángulos (Andalucía, Cataluña y Madrid como líderes) explica por qué estas zonas suelen ser los motores del mercado inmobiliario.

8.6.3 Conclusión del Análisis y Sinergia del Ecosistema

La integración de este Dashboard de Power BI con la capa analítica del proyecto cumple un rol estratégico doble. Por un lado, proporciona una herramienta de Business Intelligence macroscópica ideal para que los perfiles de gestión e inversión identifiquen patrones históricos y anomalías regionales de un solo vistazo. Por otro lado, valida la calidad del dato procesado en la **Capa Oro**, sirviendo como base empírica y auditoría visual antes de dar el salto a la inferencia predictiva en tiempo real implementada en la aplicación Streamlit. La combinación de ambas soluciones dota al proyecto de un ecosistema analítico completo, cubriendo desde el diagnóstico descriptivo del pasado hasta la proyección inteligente del mercado inmobiliario.

9. Conclusiones

(1-2 páginas)

A continuación, se presentan las conclusiones extraídas tras el desarrollo, implementación y validación del sistema predictivo de precios de vivienda:

Robustez del Pipeline de Datos y Cumplimiento de Objetivos

Se confirma que el sistema ha cumplido íntegramente con los objetivos planteados en la fase de diseño, demostrando que una arquitectura de datos bien estructurada es el pilar fundamental de cualquier proyecto de analítica avanzada. La implementación de un pipeline de datos organizado en niveles de procesamiento permitió transformar registros heterogéneos y complejos del INE en un activo de información optimizado.. Esta estructura facilitó una doble explotación: una vertiente estratégica de inteligencia de negocio y una herramienta interactiva de simulación, garantizando en todo momento la integridad de la información.

Evolución del Modelo: De la Regresión Lineal al Aprendizaje por Conjuntos

Uno de los hitos técnicos más relevantes ha sido la evolución del motor algorítmico. Durante la fase de experimentación, se identificó que modelos con métricas de precisión nominalmente superiores ($R^2 > 0.80$) presentaban una excesiva rigidez y dependencia del pasado. En consecuencia, se optó por una arquitectura de **Hist Gradient Boosting** con validación temporal (**Time Series Split**), alcanzando un R^2 consolidado de **0.7331**. Esta decisión técnica permitió lograr el equilibrio óptimo: el modelo no solo "recuerda" el historial, sino que **aprende a reaccionar dinámicamente** ante cambios en la Renta y el IPC, reduciendo el error absoluto (MAE) de forma progresiva hasta los **6.58 puntos** en las iteraciones más recientes.

La IA como Herramienta de Apoyo y Sensibilidad no Lineal

Las pruebas de validación han revelado que el modelo es capaz de capturar la heterogeneidad del mercado español. Mientras que en regiones como **Andalucía y la Comunidad Valenciana la precisión en el cotejo de 2023 fue excelente (errores inferiores al 4%)**, el sistema también fue capaz de identificar anomalías en mercados tensionados como Baleares. Es fundamental recalcar que este sistema se define como una **herramienta de apoyo a la decisión**. Aunque la IA detecta con éxito la inercia

económica, el mercado está sujeto a factores exógenos (turismo internacional, escasez de suelo o políticas monetarias) que la herramienta identifica como "desviaciones sobre los fundamentales", aportando un valor diagnóstico crucial para el analista humano.

Valoración Personal: Un Reto de Integración y Descubrimiento

Desde una perspectiva formativa y profesional, el presente proyecto ha representado un desafío que ha trascendido la mera escritura de código. Ha supuesto un recorrido integral por el ciclo de vida del dato: desde la complejidad inicial de gestionar fuentes públicas dispersas, hasta la satisfacción de transformar algoritmos abstractos en una herramienta tangible y funcional.

La exploración del ecosistema de la **Ciencia de Datos** ha permitido comprender que el valor diferencial de un ingeniero no reside únicamente en la selección del algoritmo más complejo, sino en la capacidad de conectar disciplinas como la economía, la estadística y el desarrollo de software. En este sentido, se ha otorgado una importancia capital al **Storytelling** y a la claridad de las visualizaciones, bajo la premisa de que, en entornos reales, los datos solo son útiles si pueden ser comprendidos por terceros para la toma de **decisiones estratégicas**. Este proceso de aprendizaje ha reforzado la capacidad de adaptación ante problemas imprevistos y ha despertado un gran interés por el potencial de la **Inteligencia Artificial** para extraer conocimiento de valor a partir de grandes volúmenes de datos. En última instancia, este trabajo no solo representa el cierre satisfactorio del Grado, sino la confirmación de que la tecnología, aplicada con rigor y sentido crítico, es el mejor aliado para comprender y anticipar la complejidad del mercado actual.

10. Vías futuras

(1-2 páginas)

Para dar continuidad a la investigación y mejorar el alcance de la herramienta desarrollada, se proponen las siguientes líneas de trabajo estratégicas:

10.1. Incremento de la Granularidad y Análisis Geoespacial

La actual escala a nivel de Comunidad Autónoma ofrece una visión macroeconómica necesaria, pero tiende a suavizar las disparidades internas. Una vía de desarrollo prioritaria consiste en evolucionar el análisis hacia un detalle por **provincias o municipios de alta densidad**. La integración de datos a nivel de distrito permitiría la detección de "micro-burbujas" en zonas donde la presión turística o la falta de suelo generan tensiones que las medias regionales ocultan. Para ello, se plantea el uso de librerías de geolocalización y mapas de calor interactivos que mejoren la experiencia del usuario en la identificación de focos de inversión o riesgo.

10.2. Enriquecimiento Multifuente y Big Data

La capacidad predictiva del modelo de Inteligencia Artificial podría verse potenciada significativamente mediante la ingesta de datos procedentes de fuentes diversas (sociales, financieras y demográficas). Se propone la integración de variables externas como:

- **Indicadores Financieros:** Evolución del **Euríbor** y condiciones de concesión de préstamos hipotecarios.
- **Dinámicas de Mercado:** Precio medio del alquiler y stock de vivienda nueva disponible, factores que actúan como sustitutivos o complementarios en la formación de precios.
- **Datos de Portales Inmobiliarios:** Implementación de técnicas de web scraping en portales líderes para capturar el "sentimiento del mercado" y los precios de oferta en tiempo real, complementando así los datos oficiales del INE que suelen presentar mayor desfase temporal.

10.3. Evolución del Modelo de IA y ML Predictivo

Aunque el modelo actual ofrece una gran precisión, una línea de mejora fundamental consiste en dotar al sistema de **IA Explicable (XAI)**. El objetivo es romper el concepto de "caja negra" que suele rodear a estos algoritmos, permitiendo una trazabilidad total del dato.

- **Trazabilidad de la Predicción:** Se propone implementar módulos que permitan al usuario visualizar el "porqué" de cada cifra. Esto significa que el sistema podrá desglosar la influencia exacta de cada variable, mostrando de forma clara cómo el IPC, la renta o la ubicación geográfica han interactuado para generar el precio final.
- **Modelos de Aprendizaje Profundo (Deep Learning):** Paralelamente, se plantea explorar arquitecturas avanzadas como las Redes Neuronales Recurrentes o modelos Transformer. Estas tecnologías están diseñadas específicamente para identificar patrones en series temporales, lo que permitiría captar estacionalidades muy complejas o tendencias de fondo que los modelos tradicionales podrían pasar por alto, elevando así la fiabilidad de las proyecciones a largo plazo.

10.4. Arquitectura MLOps y Despliegue en la Nube

Para transformar este prototipo en una solución de grado producción, es imperativo realizar la migración de la aplicación a un entorno **Cloud (AWS, Azure o Google Cloud)**. Esto permitiría establecer un ciclo de vida de **MLOps (Machine Learning Operations)**, automatizando:

- **Ingesta Automática:** Actualización del *dataset* cada vez que el INE o el Banco de España publiquen nuevos indicadores.
- **Re-entrenamiento Automático:** Ajuste del modelo de IA ante cambios bruscos en la economía (como periodos de alta inflación) para evitar la degradación del modelo (*data drift*).
- **Escalabilidad:** Garantizar que la herramienta pueda ser consultada por múltiples usuarios simultáneamente sin pérdida de rendimiento.

11. Bibliografía/Webgrafía

(1-2 páginas)

PwC España. (2025). Récord PropTech y ConTech en España: impulso a la innovación inmobiliaria.

<https://www.pwc.es/es/sala-prensa/notas-prensa/2025/record-proptech-contech-espana-i-mpulso-innovacion-inmobiliario.html>

DataVenues. (2025). Soluciones de Big Data Inmobiliario.

<https://datavenues.com/>

API Catalunya. (2025). PropTech Trends e innovación inmobiliaria en España.

<https://research.api.info/category/parent-proptech/>

Instituto Nacional de Estadística (INE). (2025). Servicio de difusión de información y descarga de datasets estructurados. <https://www.ine.es/>

Banco de España. (2024). El mercado de la vivienda residencial en España: evolución reciente y comparación internacional. Documento Ocasional n.º 2413.

<https://www.bde.es/wbe/es/publicaciones/analisis-economico-investigacion/documentos-ocasionales/el-mercado-de-la-vivienda-residencial-en-espana-evolucion-reciente-y-comparacion-internacional.html>

Fu, Y. (2024). A Comparative Study of House Price Prediction Using Linear Regression and Random Forest Models. Highlights in Science, Engineering and Technology, Vol. 107.

<https://pdfs.semanticscholar.org/730a/1a0f5ccf98ea4c96d33aea97fa800e4b0a82.pdf>

Databricks. (2024). What is Data Storytelling? [Blog post].

<https://www.databricks.com/blog/what-is-data-storytelling>

Consejo de la Juventud de España (CJE). (2025). Informe del Observatorio de Emancipación: La tasa de emancipación alcanza el mínimo histórico desde 2006.

<https://www.cje.org/observatorio1s2024/>

International Organization for Standardization. (1998). *Information technology — 8-bit single-byte coded graphic character sets — Part 1: Latin alphabet No. 1* (ISO/IEC Standard No. 8859-1:1998). <https://www.iso.org/standard/28245.html>

Scikit-learn Developers (2024). HistGradientBoostingRegressor: Histogram-based Gradient Boosting Regression Tree. Scikit-learn Documentation.

<https://scikit-learn.org/stable/modules/generated/sklearn.ensemble.HistGradientBoostingRegressor.html>

Microsoft. (2025). *Power BI Desktop* (Versión de febrero de 2025) [Software de computación]. Microsoft Corporation. <https://powerbi.microsoft.com/>

Plotly Technologies Inc. (2024). *Collaborative data science* [Software de gráficos interactivos]. Plotly. <https://plot.ly>

Python Software Foundation. (2024). *Python Language Reference* (Versión 3.11) [Entorno de software]. <https://www.python.org>

Streamlit Inc. (2024). *Streamlit: The fastest way to build and share data apps* (Versión 1.32) [Framework de software]. <https://streamlit.io>

The Pandas Development Team. (2024). *pandas-dev/pandas: Pandas* (Versión 2.2) [Software]. Zenodo. <https://pandas.pydata.org>

Waskom, M. L. (2021). Seaborn: statistical data visualization. *Journal of Open Source Software*, 6(60), 3021. <https://doi.org/10.21105/joss.03021>

12. Anexos

12.1 Manual de Instalación

1. Requisitos Previos e Ingesta Histórica (Jupyter): El entorno base se apoya en la distribución *Anaconda*. Para visualizar y ejecutar el pipeline científico completo, el analista simplemente debe iniciar *Anaconda Navigator*, lanzar *Jupyter Notebook* y abrir el cuaderno *HouseData.ipynb*. Al ejecutar secuencialmente todas sus celdas (*Run All*), el script realiza de manera automática la limpieza de datos, el cálculo de variables de la Capa Oro —guardando el archivo *house_data_gold.csv*— y, justo a continuación, entrena el modelo de Inteligencia Artificial, exportando el archivo binario serializado *modelo_ipv_v2.pkl*.

2. Explotación del Dashboard (Power BI): La capa analítica descriptiva se encuentra consolidada en el archivo 'DashboardHouseData.pbix'. Para su ejecución, el usuario simplemente debe contar con la aplicación **Power BI Desktop** (disponible de forma 100% gratuita en la Microsoft Store o en la web oficial de Microsoft). Una vez instalada, basta con realizar **doble clic** sobre el archivo para que el cuadro de mandos interactivo se despliegue localmente, quedando listo para su exploración mediante los segmentadores y filtros regionales.

3. Despliegue del Servidor Predictivo (Streamlit): Al ser una solución web interactiva en tiempo real, es la única herramienta que requiere el uso de la consola. El usuario debe abrir *Anaconda Prompt* (o la Terminal del sistema), navegar hasta el directorio raíz del proyecto y lanzar la interfaz con los siguientes comandos:

```
cd ruta/de/tu/carpeta/ProyectoHouseData
pip install streamlit scikit-learn pandas plotly joblib
streamlit run app/ModeloRegresionAI.py
```


12.2 Manual de Usuario (Guía de Explotación y Análisis)

Nivel 1: El Origen (Jupyter Notebooks)

- **Qué es:** El laboratorio científico donde se "cocinan" los datos.
- **Para quién:** Usuarios técnicos o auditores que quieran ver cómo se pasó de los datos sucios del INE a la Capa Oro.
- **Cómo se usa:** Se ejecutan las celdas de código para observar el *Storytelling*: pasando por las 5 fases (Ingesta, Limpieza, Consolidación, EDA(Visualizaciones), Modelo).

Nivel 2: El Diagnóstico (Dashboard Power BI)

- **Qué es:** La herramienta de análisis histórico (el pasado y el presente).
- **Cómo se usa:**
 - * **Filtros:** Selecciona tu Comunidad Autónoma y el año en los desplegables.
 - **Mapa de Burbujas:** Mira el tamaño de la burbuja para entender la presión del precio en cada zona.
 - **Gráfico de Dispersión:** Busca puntos "fuera de la línea" para detectar dónde la vivienda es demasiado cara respecto a la renta (zonas tensionadas).
- **Objetivo:** Entender "qué ha pasado" hasta ahora en el mercado inmobiliario.

Nivel 3: El Oráculo (App Streamlit)

- **Qué es:** La herramienta de simulación y futuro.
- **Cómo se usa:**
 - **Entrada de datos:** Mueve los deslizadores (*sliders*) para cambiar el IPC o la Renta.
 - **Predicción:** Pulsa el botón para que la IA calcule el nuevo precio de la vivienda.
 - **Semáforo de Riesgo:**
 - **Verde:** Mercado respira, estabilización IPV.
 - **Rojo:** Riesgo de exclusión financiera, aumento IPV.
- **Objetivo:** Ver "qué pasaría si..." cambian las condiciones económicas.

12.3 Tablas

Ranking	Comunidad Autónoma	Nivel de Riesgo	Hallazgo del Análisis
1º	Canarias	Extremo	Ratio más alto de España; brecha salarial crítica.
2º	Andalucía	Muy Alto	Desequilibrio entre precios y renta media baja.
3º	Baleares	Muy Alto	Presión del mercado externo y escasez de oferta.
4º	Madrid	Alto	Precios nominales máximos, compensados por rentas altas.
5º	Cataluña	Alto	Tensión sostenida en áreas metropolitanas.

Tabla 1: Clasificación Riesgo CCAA

Fuente: Creación Propia

Variable	Tipo de Dato	Descripción	Origen / Método de Cálculo
CCAA	Categórica	Comunidad Autónoma analizada (17 regiones).	Registro Original (INE)
Año	Temporal / Int	Año correspondiente a la serie histórica (2008-2022).	Registro Original (INE)
Indice_IPC	Float	Índice de Precios al Consumo (Inflación).	Registro Original (INE)
Precio_Vivienda_IPV	Float	Índice de Precios de Vivienda. (Variable Objetivo).	Registro Original (INE)
Renta_Media	Int	Capacidad salarial media anual por hogar.	Registro Original (INE)
Pob_Adulta	Float	Población en edad laboral y senior combinada.	Registro Original (INE)

Pob_Joven	Float	Población en edad de emancipación.	Registro Original (INE)
Pob_Senior	Float	Población en edad de jubilación.	Registro Original (INE)
Ratio_Esfuerzo	Float	Relación de accesibilidad (Precio / Renta).	Procesado (Capa Gold)
Renta_Ajustada_IPC	Float	Capacidad de compra real (Renta / IPC).	Feature Engineering
Pct_Pob_Joven	Float	Peso porcentual de la juventud sobre el total.	Feature Engineering
IPV_Anterior	Float	Inercia del precio del año previo (Lag 1).	Feature Engineering (Shift)

Tabla 2: Diccionario Datos Dataset Final

Fuente: Elaboración Propia

Actor	Acción	Resultado del Sistema
Joven Emancipado	Ajusta su sueldo en el simulador.	El sistema predice la viabilidad de compra en su región.
Analista Público	Filtra por el año 2023 en Power BI.	El mapa resalta las zonas donde hace falta el Bono Alquiler.
Investigador	Observa la Matriz de Correlación.	Valida la relación entre inflación y coste de vida.

Tabla 3: Clasificación Utilidad del Cuadro de Mandos

Fuente: Elaboración Propia

ID	Prueba	Ámbito	Estado
PR-01	Integridad Estructural	Datos	Éxito
PR-02	Validación Temporal	IA	Éxito
PR-03	Inferencia en Tiempo Real	Interfaz	Éxito
PR-04	Cotejo de Realidad (Backtesting 2023)	IA/Negocio	Éxito

Tabla 4. Resumen Pruebas Ejecutadas

Fuente: Elaboración Propia

12.4 Imágenes




Figura 15. Gráfico Barras Brecha España/UE

Fuente: Cuaderno Jupyter




Figura 17. Mapa Renta por CCAA

Fuente: Cuaderno Jupyter




Figura 19. Scatter Plot Esfuerzo CCAA y Población Juvenil

Fuente: Cuaderno Jupyter




Figura 22. Diseño Arquitectura Datos

Fuente: Elaboración Propia



Figura 30. Simulación de mercado Extremadura.

Fuente: App Streamlit




Figura 31. Detección de cambio tendencia IPV.

Fuente: App Streamlit




Figura 32. Tendencia Contraria

Fuente: App Streamlit